

HealthSearch — Motor de Busca Híbrido

BM25 (léxico) + Busca Semântica Vetorial (embeddings) + Reciprocal Rank Fusion (RRF)

Relatório Técnico — Desafio Integrador | UNIPÊ — Centro Universitário de João Pessoa

Disciplina: Tendências em Ciência da Computação — Recuperação de Informação / PLN | Prof. Me. Ricardo Roberto de Lima

Integrante	Matrícula	Principal contribuição
		Motor Léxico (BM25) e pré-processamento
		Motor Semântico e simulação vetorial
		Fusão RRF, dashboard Streamlit e relatório

1. Contexto e Problema


A HealthTech Solutions enfrenta um dilema clássico de Recuperação de Informação em prontos-socorros: buscas puramente léxicas (BM25) não recuperam diretrizes quando o profissional usa sinônimos leigos (ex.: "infarto"/"ataque cardíaco" vs. "síndrome coronariana aguda"), enquanto buscas puramente semânticas (embeddings) perdem precisão em termos exatos como códigos de exame (CÓD-ECG-12D) e dosagens (AAS 100mg). O HealthSearch resolve esse dilema combinando os dois motores por meio de Reciprocal Rank Fusion (RRF), preservando simultaneamente cobertura semântica e precisão lexical.

2. Arquitetura da Solução

Fase	Componente	Descrição técnica
1	Ingestão e Pré-processamento	Corpus de 6 diretrizes clínicas hardcoded; normalização (minúsculas), remoção de caracteres especiais e stopwords em português via regex + lista curada.
2	Motor Léxico (BM25 Okapi)	Biblioteca rank_bm25; parâmetros k1 (saturação, 0–3, padrão 1.2) e b (normalização por tamanho, 0–1, padrão 0.75) calibráveis via sliders no Streamlit.
3	Motor Semântico Vetorial	Tenta carregar Sentence-Transformers (paraphrase-multilingual-MiniLM-L12-v2). Sem internet/modelo, cai em modo simulado documentado: expansão de termos em "conceitos clínicos" equivalentes (dicionário de sinônimos) + vetorização TF-IDF + similaridade de cosseno.
4	Fusão RRF	$Score_RRF(D) = \alpha \cdot [1/(k_rrf + Rank_BM25)] + (1-\alpha) \cdot [1/(k_rrf + Rank_Semântico)]$, com $k_rrf=60$ fixo e α ajustável (0–1) via slider, balanceando peso léxico vs. semântico.

3. Estudo de Caso: Comparação de Ranks

Para a consulta leiga "ataque cardíaco", o BM25 falha completamente (score 0 em todos os documentos, pois nenhum termo exato coincide com o vocabulário técnico do corpus). O motor semântico, por reconhecer o conceito clínico equivalente, recupera corretamente o Doc 1 (síndrome coronariana / ECG) e o Doc 2 (infarto agudo do miocárdio) — demonstrando na prática o ponto cego léxico descrito no estudo de caso.



Em contrapartida, para consultas por código exato (ex.: **CÓD-ECG-12D**) ou dosagem (ex.: **AAS 100mg**), o BM25 recupera os documentos corretos com alta precisão (match exato de token), papel que a fusão RRF preserva ao combinar as duas listas de ranking — em vez de descartar o sinal léxico em favor do semântico, ou vice-versa.

4. Divisão de Tarefas da Equipe

Atividade	Responsável
Pré-processamento (Fase 1) e curadoria do corpus/stopwords	Integrante 1
Implementação e calibração do BM25 (Fase 2)	Integrante 1
Motor semântico e dicionário de conceitos clínicos (Fase 3)	Integrante 2
Algoritmo de Fusão RRF (Fase 4) e validação matemática	Integrante 2
Dashboard Streamlit, sliders e abas comparativas	Integrante 3
Testes, gráfico comparativo e redação do relatório técnico	Integrante 3

5. Conclusão

O protótipo demonstra que a busca híbrida, via RRF, é robusta a ambos os pontos cegos identificados no estudo de caso: mantém alta cobertura para sinônimos médicos (motor semântico) sem sacrificar precisão em termos técnicos exatos, como códigos de exame e dosagens (motor léxico BM25). O parâmetro α permite à equipe clínica ajustar esse equilíbrio conforme o perfil predominante das buscas do pronto-socorro.