

HealthSearch: Motor de Busca Híbrido

BM25 (léxico) + Busca Semântica Vetorial (embeddings) + Reciprocal Rank Fusion (RRF)

Relatório Técnico do Desafio Integrador | UNIPÊ - Centro Universitário de João Pessoa

Disciplina: Tendências em Ciência da Computação: Recuperação de Informação / Processamento de Linguagem Natural

Autora: Maria Clara Gouveia

1. Contexto e Problema

A HealthTech Solutions enfrenta um dilema clássico de Recuperação de Informação em prontos socorros: buscas puramente léxicas (BM25) não recuperam diretrizes quando o profissional usa sinônimos leigos (por exemplo, "infarto" ou "ataque cardíaco" em vez de "síndrome coronariana aguda"), enquanto buscas puramente semânticas (embeddings) perdem precisão em termos exatos, como códigos de exame (CÓD-ECG-12D) e dosagens (AAS 100mg). O HealthSearch resolve esse dilema combinando os dois motores por meio de Reciprocal Rank Fusion (RRF), preservando simultaneamente cobertura semântica e precisão lexical.


2. Arquitetura da Solução

A aplicação foi estruturada em quatro fases integradas em um único dashboard Streamlit:

- Fase 1, Ingestão e Pré-processamento:** corpus de seis diretrizes clínicas pré-carregado no código; normalização do texto (conversão para minúsculas), remoção de caracteres especiais e eliminação de stopwords em português, feitas com expressões regulares e uma lista curada de termos.
- Fase 2, Motor Léxico (BM25 Okapi):** implementado com a biblioteca rank_bm25. Os parâmetros k1 (saturação de frequência, variando de 0 a 3, padrão 1.2) e b (normalização por tamanho do documento, variando de 0 a 1, padrão 0.75) podem ser calibrados dinamicamente por sliders na barra lateral.
- Fase 3, Motor Semântico Vetorial:** o sistema tenta carregar um modelo real de embeddings (Sentence-Transformers, paraphrase-multilingual-MiniLM-L12-v2). Caso a biblioteca não esteja instalada ou não haja acesso à internet para baixar o modelo, o app assume automaticamente um modo de simulação vetorial documentado: os termos da consulta e dos documentos são expandidos para "conceitos clínicos" equivalentes por meio de um dicionário de sinônimos médicos, e então vetorizados com TF-IDF, calculando a similaridade de cosseno entre consulta e documentos.
- Fase 4, Fusão RRF:** o score final de cada documento é calculado pela fórmula $\text{Score_RRF}(D) = \alpha \times [1 / (k_rrf + \text{Rank_BM25})] + (1 - \alpha) \times [1 / (k_rrf + \text{Rank_Semântico})]$, com k_rrf fixo em 60 e α ajustável entre 0 e 1 por meio de um slider, permitindo balancear o peso léxico e o peso semântico na fusão final.

3. Estudo de Caso: Comparação de Ranks

Para a consulta leiga "ataque cardíaco", o BM25 falha completamente: o score é zero em todos os documentos, pois nenhum termo exato coincide com o vocabulário técnico do corpus. O motor semântico, por reconhecer o conceito clínico equivalente, recupera corretamente o Doc 1 (síndrome coronariana e eletrocardiograma) e o Doc 2 (infarto agudo do miocárdio), demonstrando na prática o ponto cego léxico descrito no estudo de caso.



Em contrapartida, para consultas por código exato, como CÓD-ECG-12D, ou por dosagem, como AAS 100mg, o BM25 recupera os documentos corretos com alta precisão, por meio do match exato de token. Esse sinal léxico é preservado pela fusão RRF, que combina as duas listas de ranking em vez de descartar um dos sinais em favor do outro.

4. Conclusão

O protótipo demonstra que a busca híbrida, viabilizada pelo RRF, é robusta a ambos os pontos cegos identificados no estudo de caso: mantém alta cobertura para sinônimos médicos, graças ao motor semântico, sem sacrificar a precisão em termos técnicos exatos, como códigos de exame e dosagens, graças ao motor léxico BM25. O parâmetro alfa permite ajustar esse equilíbrio conforme o perfil predominante das buscas realizadas no pronto-socorro.

Todas as etapas do projeto, desde o pré-processamento e a implementação do BM25 até o motor semântico, a fusão RRF, o dashboard em Streamlit e a redação deste relatório, foram desenvolvidas individualmente por Maria Clara Gouveia.